Práctica 4

Introducción al Aprendizaje Automático

Escuela Politécnica Superior de Córdoba

Universidad de Córdoba

Grado de Ingeniería Informática

Autores:

Juan Luis Prieto Panadero
Alberto Álvarez Mejías

1. Práctica 4: Clasificación y el Valor del Error

1.1. Objetivo de la práctica

En esta práctica se entrena un clasificador probabilístico sencillo para un problema de detección de fraude y se analiza cómo el umbral de decisión afecta a los errores y al coste total. El objetivo no es únicamente medir el rendimiento predictivo del modelo, sino estudiar el impacto real de sus decisiones a partir de una matriz de costes.

1.2. Descripción del problema

Se trabaja con un problema de clasificación binaria:

- **Clase 0**: transacción normal.
- **Clase 1**: transacción fraudulenta.

En este contexto, los errores no tienen el mismo coste:

- **Falso Negativo (FN)**: no detectar un fraude $\rightarrow$ 200
- **Falso Positivo (FP)**: bloquear una transacción legítima $\rightarrow$ 10

Por tanto, la decisión final no debe evaluarse solo por el número de aciertos, sino por el coste económico asociado a los errores.

1.3. Tarea 1: Análisis con el umbral por defecto ($\tau = 0{,}5$)

Modelo utilizado

En esta práctica se ha utilizado una **Regresión Logística** como clasificador base. El modelo se ha entrenado con el conjunto de entrenamiento y se ha evaluado sobre el conjunto de prueba.

Matriz de confusión

A continuación se muestra la matriz de confusión obtenida usando el umbral estándar $\tau = 0{,}5$.

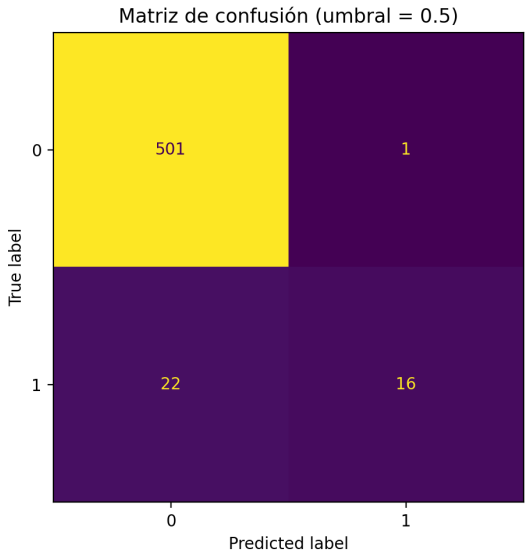

Figura 1: Matriz de confusión para el umbral $\tau = 0{,}5$.

A partir de esta matriz, se obtienen los siguientes valores:

- Verdaderos Positivos (TP): `1`
- Verdaderos Negativos (TN): `501`
- Falsos Positivos (FP): `1`
- Falsos Negativos (FN): `22`

Cálculo del coste total

El coste total se calcula mediante la expresión:

$$\text{Coste Total} = (FP \cdot 10) + (FN \cdot 200)$$

Sustituyendo los valores obtenidos:

$$\text{Coste Total} = (\texttt{1} \cdot 10) + (\texttt{22} \cdot 200) = \texttt{4410}$$

Interpretación

Comentario del alumno: *Con el umbral por defecto de 0.5 el modelo no resulta adecuado para este problema. Aunque casi no genera falsos positivos, deja muchos fraudes sin detectar (22 falsos negativos), y eso dispara el coste económico porque cada falso negativo cuesta 200 euros. El coste total obtenido es 4410 euros, por lo que el umbral estándar no está controlando bien el error más caro. En un entorno real no lo usaría sin revisarlo y ajustaría el umbral para minimizar el coste total.*

1.4. Tarea 2: Estudio de probabilidades y umbrales

Análisis de distintos umbrales

En lugar de trabajar únicamente con la clase predicha, se han utilizado las probabilidades estimadas por el modelo para la clase positiva y se han evaluado distintos valores del umbral τ entre 0 y 1, en pasos de 0.05.

La Tabla 1 resume los resultados obtenidos para varios umbrales.

Cuadro 1: Resumen de resultados para distintos umbrales.

Umbral	**FP**	**FN**	**Coste Total (€)**
0.00	502	0	5020
0.05	112	9	2920
0.10	42	14	3220
0.15	22	15	3220
0.20	13	15	3130
⋮	⋮	⋮	⋮
1.00	0	38	7600

Observaciones

Comentario del alumno: *Al variar el umbral se observa un comportamiento claro: cuando el umbral baja, el modelo clasifica más operaciones como fraude, por lo que aumentan los falsos positivos pero disminuyen los falsos negativos. En cambio, cuando el umbral sube, el modelo se vuelve más estricto, reduce los falsos positivos y deja escapar más fraudes, aumentando los falsos negativos. En este problema aparece un compromiso directo entre ambos tipos de error. Dado que un falso negativo cuesta mucho más que un falso positivo (200 euros frente a 10 euros), resulta más razonable aceptar algunos falsos positivos adicionales si con ello se reducen fraudes no detectados y baja el coste total.*

1.5. Tarea 3: Optimización del coste

Gráfica de coste frente a umbral

La Figura 2 muestra la evolución del coste total en función del umbral de decisión.

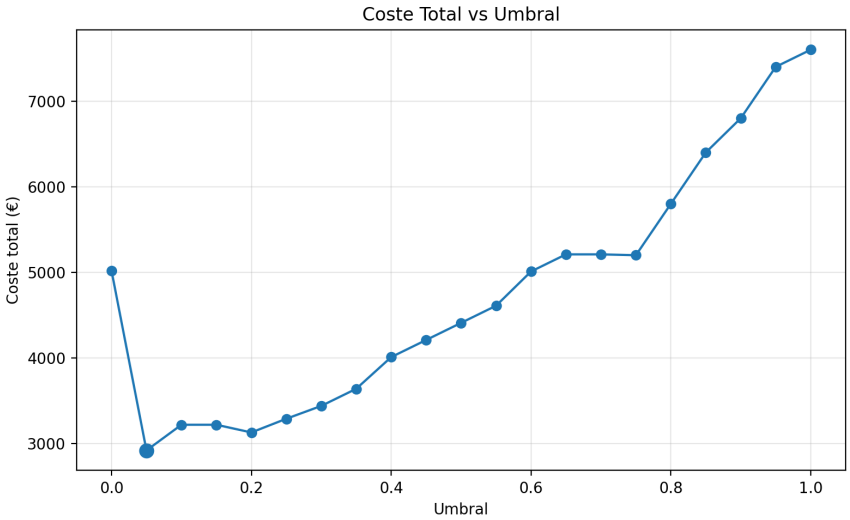

Figura 2: Coste total en función del umbral de decisión.

Umbral óptimo

A partir de la gráfica y de la tabla anterior, el umbral que minimiza el coste total es:

$$\tau^* = \texttt{[SUSTITUIR]}$$

El coste total mínimo asociado es:

$$\text{Coste mínimo} = \texttt{[SUSTITUIR]}$$

Interpretación

Comentario del alumno: *Explica aquí si el umbral óptimo es mayor o menor que 0.5 y por qué ese valor tiene sentido en este problema.*

Guía para redactar:

- ¿Por qué el mínimo no tiene por qué aparecer en 0.5?
- ¿Qué relación tiene ese valor con la diferencia de costes entre FP y FN?
- ¿Qué estrategia parece más razonable para el banco: conservadora o permisiva?

1.6. Tarea 4: Curvas ROC y Precision-Recall

Curva ROC

La Figura 3 muestra la curva ROC obtenida para el modelo.

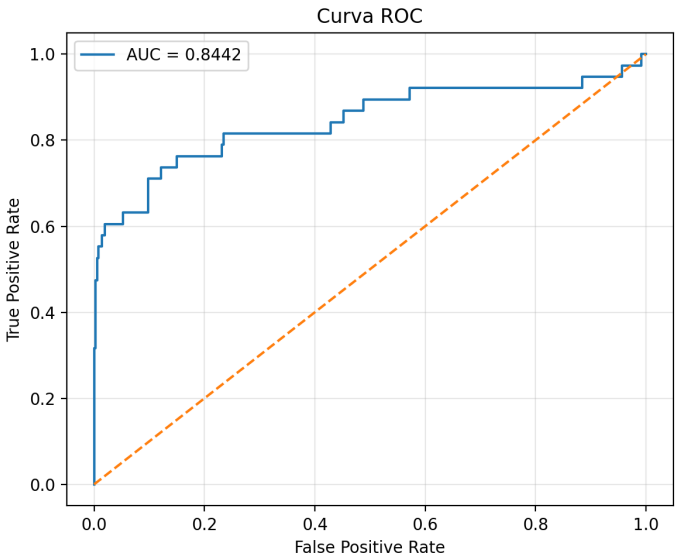

Figura 3: Curva ROC del clasificador.

Curva Precision-Recall

La Figura 4 muestra la curva Precision-Recall del modelo.

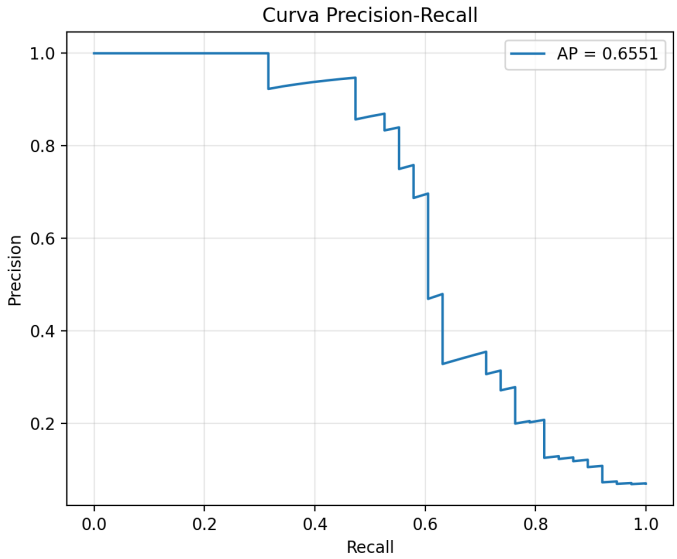

Figura 4: Curva Precision-Recall del clasificador.

Discusión

Comentario del alumno: *Si el dataset está desbalanceado, razona cuál de las dos curvas resulta más útil para valorar la utilidad real del modelo en este problema.*

Guía para redactar:

- ¿Qué información aporta la curva ROC?
- ¿Qué información aporta la curva Precision-Recall?

- ¿Cuál refleja mejor el comportamiento sobre la clase minoritaria?

1.7. Decisión final de ingeniería

Imaginando que formo parte del equipo técnico del banco, la política de decisión que recomendaría sería la siguiente:

`[REDACTAR AQUÍ UNA PROPUESTA BREVE Y ARGUMENTADA]`

Esta decisión se basa en:

- el coste asociado a los falsos positivos y falsos negativos;
- el umbral que minimiza el coste total;
- el equilibrio entre seguridad y molestias para el cliente;
- la interpretación conjunta de las curvas ROC y Precision-Recall.

1.8. Conclusiones

Comentario final del alumno: *Resume aquí qué has aprendido con esta práctica y explica por qué en clasificación no todos los errores valen lo mismo.*

Aspectos que conviene mencionar:

- que el umbral de decisión no es fijo ni universal;
- que cambiar el umbral modifica la relación entre FP y FN;
- que el contexto del problema debe influir en la evaluación;
- que una métrica general no siempre refleja el impacto real de un modelo.